



Informe técnico

Machine Learning No Supervisado

Noviembre 2025

Presentado por:

- César Bladimir Romero Rugamas.
- Guillermo Ulises Palacios Flores.
- Walter Alexánder Salguero Rodríguez.

Introducción

El presente Informe corresponde al trabajo final realizado en la Materia de Machine Learning no supervisado de la Maestría de Ciencia de Datos e Inteligencia de negocios. Aplicamos la reducción de dimensionalidad es un conjunto de técnicas esenciales en el análisis de datos modernos. Su objetivo principal es transformar conjuntos de datos con un gran número de variables en representaciones más concisas, manteniendo la información más relevante. Una metodología crucial para superar un fenómeno que dificulta el análisis y la visualización cuando se manejan demasiadas variables, como señaló Bellman en 1957.

Este informe explorará los conceptos fundamentales, las técnicas clave y las aplicaciones prácticas de la reducción de dimensionalidad con un enfoque particular en el Análisis de Componentes Principales (PCA), t-SNE y UMAP. Además realizar el Clustering con la popular Kmeans y explorar HDBSCAN .

Se presenta un caso de estudio aplicado a datos censales de vivienda, demostrando cómo estas técnicas facilitan la exploración y el descubrimiento de patrones latentes en grandes volúmenes de información.

En el ámbito del análisis de datos, cada fila de un conjunto de datos puede ser interpretada como un vector en un espacio n -dimensional, donde ' n ' representa el número de variables. Esta conceptualización vectorial permite la aplicación de diversas operaciones matemáticas fundamentales para entender la estructura y las relaciones dentro de los datos.

Las visualizaciones permitirán identificar agrupamientos, diferencias regionales y estructuras latentes en los datos, proporcionando una comprensión más profunda de las características de los hogares salvadoreños

Indice

Objetivo principal	- 5 -
Conceptos Fundamentales PCA	- 5 -
Metodología del Proyecto	- 7 -
Caso de Estudio: Análisis Exploratorio de Datos Censal	- 8 -
Exploración Visual de Variables	- 9 -
Variables y etiquetas y selección para clustering	- 11 -
Conclusiones del Preprocesamiento y Exploración Inicial	11
Reducción de Dimensionalidad	12
Segundo Análisis utilizando todo el Set de Datos Reducción de Dimensionalidad	19
Conceptos y Técnicas de Clustering	23
Construcción del Modelo	24
Interpretación y Conclusiones del Análisis de Clusters Notebook 04	27
Descripción de los Datos Utilizados	27
Columnas Presentes en el Archivo	27
Conclusiones y Próximos Pasos	31

Tabla de Siglas y Abreviaciones

Sigla / Abreviación	Significado
CPV	Censo de Población y Vivienda
PCA	Principal Component Analysis (Análisis de Componentes Principales)
UMAP	Uniform Manifold Approximation and Projection
t-SNE	t-Distributed Stochastic Neighbor Embedding
CSV	Comma-Separated Values (Archivo de valores separados por comas)
COD_PROP	Código único de propiedad
COD_VIV	Código único de vivienda
GHS_DUG_L1	Clasificación geoespacial nivel 1 (Global Human Settlement Layer)
V03_VIV_PARED	Material de las paredes
V04_VIV_TECHEO	Material del techo
V05_VIV_PISO	Material del piso
V06_VIV_CUARTOS	Número de cuartos
V07_VIV_TENENCIA	Forma de tenencia de la vivienda
V08_VIV_TIPO_SANIT	Tipo de servicio sanitario
V09_VIV_USO_SANIT	Uso del servicio sanitario
V10_VIV_AGUAS_GRISES	Manejo de aguas grises
V11_VIV_AGUA	Disponibilidad de agua
V12_VIV_PROVIENE_AGUA	Procedencia del agua
V12_1_VIV_ABASTO_AGUA	Tipo de abastecimiento de agua
V13_VIV_FUENTE_ENERGIA	Procedencia de la energía eléctrica
V14_VIV_COMBUSTIBLE_COCINA	Tipo de combustible utilizado para cocinar
V15_VIV_ELIM_BASURA	Método de eliminación de residuos sólidos
V16_VIV_OLLA_COMUN	Participación en olla común
V17_VIV_NUM_HOGARES	Número de hogares en la vivienda
V18_VIV_NUM_PERSONAS	Número total de personas en la vivienda
INFO_TOTAL	Indicador agregado del hogar (personas o tipo de hogar)

Objetivo principal

La preparación y exploración de un conjunto de datos censales de vivienda, utilizando técnicas de preprocesamiento para facilitar un análisis posterior de reducción de dimensionalidad y clustering. El objetivo es identificar patrones latentes en los hogares salvadoreños a partir del Censo de Población y Vivienda 2024

Conceptos Fundamentales PCA

El Análisis de Componentes Principales (PCA) es una de las técnicas de reducción de dimensionalidad más utilizadas. Su objetivo es transformar un conjunto de variables posiblemente correlacionadas en un nuevo conjunto de variables no correlacionadas, llamadas componentes principales.

- **Transformación Lineal:** Cada componente principal es una combinación lineal de las variables originales.
- **Maximización de Varianza:** El primer componente principal captura la mayor cantidad de varianza posible en los datos, el segundo componente captura la mayor varianza restante ortogonal al primero, y así sucesivamente.
- **Reducción Eficiente:** Permite reducir un conjunto de 'n' variables a 'm' componentes (donde $m < n$), minimizando la pérdida de información al priorizar los componentes que explican la mayor variabilidad.

En nuestro caso de estudio, los primeros 4 componentes retienen el 87.09% de la varianza total, lo que es un resultado excelente para la visualización y segmentación de datos complejos.

Propósito de Reducir Dimensiones

Visualización Mejorada

Permite proyectar datos complejos en 2D o 3D, facilitando el análisis gráfico y la identificación de patrones visuales.

Eliminación de Ruido

Ayuda a descartar variables irrelevantes o redundantes que pueden introducir ruido y dificultar el análisis.

Mejora de Modelos

Previene el sobreajuste, reduce la carga computacional y mejora la eficiencia de los algoritmos de aprendizaje automático.

Descubrimiento de Patrones

Revela estructuras latentes y relaciones ocultas en los datos que no son evidentes en su forma original de alta dimensión.

Técnicas No Lineales: t-SNE y UMAP

t-SNE (t-Distributed Stochastic Neighbor Embedding) Preservación Local: Se enfoca en mantener las distancias entre puntos cercanos en el espacio de alta dimensión, lo que lo hace ideal para visualizar clústeres.

Visualización de Clústeres: Excelente para revelar agrupamientos densos y la estructura de los datos a nivel local.

Sensibilidad a Hiperparámetros: Es sensible a parámetros como la perplejidad y la tasa de aprendizaje, que deben ajustarse cuidadosamente para obtener resultados óptimos

UMAP (Uniform Manifold Approximation and Projection)

Preservación Global y Local: A diferencia de t-SNE, UMAP busca preservar tanto la estructura local como la global de los datos.

Eficiencia y Escalabilidad: Es significativamente más rápido y escalable que t-SNE, lo que lo hace adecuado para conjuntos de datos muy grandes.

Base Teórica Sólida: Se fundamenta en la teoría de manifolds y grafos topológicos,

Metodología del Proyecto

Flujo Técnico Modular en Jupyter

Análisis desarrollado en notebooks Jupyter, organizados por etapas para un flujo de



Comunicación Ágil por WhatsApp

Uso de WhatsApp para compartir avances, validar decisiones y resolver dudas rápidamente.

Repositorio Reproducible en GitHub

Gestión del proyecto en un repositorio público para trazabilidad, colaboración y reproducibilidad

Flujo Técnico Detallado


- **Notebook 01_exploracion_y_preprocesamiento_de_datos:** Exploración inicial, limpieza, renombrado de variables según diccionario oficial, tratamiento de valores especiales y exportación de dataset_limpio.csv.
- **Notebook 02_reduccion_de_dimensionalidad:** Aplicación de técnicas de reducción de dimensionalidad (PCA, UMAP) sobre variables seleccionadas. Este cuaderno tiene un enfoque ****interpretativo**** más claro: visualizaremos cómo cambian los patrones de las viviendas según su ****grado de urbanización (GHS_L1)**** y su relación con:

Notebook 03_clustering_final: Aplicación de algoritmos de clustering (KMeans, GMM HDBSCAN) y visualización de resultados.
- **Notebook 04:** Validación de agrupamientos y análisis técnico.

Caso de Estudio: Análisis Exploratorio de Datos Censal

El dataset utilizado es "Viviendas_CPV_2024_SV.csv" y el diccionario de variables es "Diccionario bases de datos -CPV 2024 SV.xlsx". El dataset utilizado es "Viviendas_CPV_2024_SV.csv" y el diccionario de variables es "Diccionario bases de datos -CPV 2024 SV.xlsx". Además en Anexos realizamos la aplicación de PCA utilizando las 6 millones de fila con el objetivo de comparar resultados

Proceso de Preprocesamiento



Reemplazados códigos especiales. Ejemplos NA counts:



V1.2. Tipo de Vivienda Colectiva	2268976
V2.2. Tipo de Vivienda Desocupada	1841081
V12.1. Abastecimiento de agua	731506
V9. Uso del servicio sanitario	535574
V8. Tipo de servicio sanitario	480125
V7. Forma de tenencia de la vivienda	479712
V13. Procedencia de la energía eléctrica	478799
V4. Material del techo	477871
V5. Material del piso	477640
V15. Eliminación de basura (residuos sólidos)	477351

dtype: int64

Muestra las correlaciones entre un conjunto amplio de variables censales de vivienda (tipo de vivienda, materiales, servicios, abastecimiento, tenencia, saneamiento, etc.). Este tipo de gráfico es útil para identificar patrones, grupos de variables relacionadas y posibles redundancia

Se identifica variables correlacionales

- Materiales / Estructura
- Tipo y condición de vivienda
- Servicios básicos



Renombrar columnas utilizando el diccionario: bloque de código destacado

Para facilitar el análisis, sugerimos emplear el siguiente procedimiento para cargar y aplicar el diccionario de variables. El bloque se presenta con formato HTML desde VsCode para facilitar la lectura y resaltar la sintaxis.

Descripción: Este código automatiza la identificación y el renombrado de columnas, facilitando la interpretación y la limpieza de datos censales.

```
# 4.1 cargar diccionario
dicc = pd.read_excel(dic_path, dtype=str)
dicc.columns = dicc.columns.astype(str).str.lower().str.strip()
print("Columnas diccionario:", list(dicc.columns))

# ajustar nombres de columnas del diccionario según tu archivo (ej: 'mnemónico',
'etiqueta')

col_codigo = None
col_desc = None
for c in dicc.columns:
    if "mnem" in c or "mnemónico" in c or "mnemónico" in c.lower():
        col_codigo = c
    if "etiqu" in c or "etiqueta" in c or "label" in c.lower():
        col_desc = c

# si no encontró, imprimir columnas para que corrijas

if col_codigo is None or col_desc is None:
    print("Revisá las columnas del diccionario y asigná manualmente. Columnas
disponibles:", list(dicc.columns))
else:
    dicc[col_codigo] = dicc[col_codigo].astype(str).str.strip()
    dicc[col_desc] = dicc[col_desc].astype(str).str.strip()
    mapa = dict(zip(dicc[col_codigo], dicc[col_desc]))

    # Renombrar solo si los mnemónicos existen en df.columns

    mapa_filtrado = {k:v for k,v in mapa.items() if k in df.columns}
    df.rename(columns=mapa_filtrado, inplace=True)
    print("Renombradas (preview):", list(mapa_filtrado.items())[:10])
```

Variables y etiquetas y selección para clustering

mnemónico	etiqueta
DEPTO	Clave del departamento
DEPTODESC	Departamento de residencia
MUNIC	Clave del municipio
MUNICDESC	Municipio de residencia
DISTO	Clave del distrito
DISTODESC	Distrito de residencia
COD_PROP	Código único de propiedad
COD_VIV	Código único de vivienda
I01_IDEM_ESTRUC	E1. Tipo de Estructura
V01_VIV	V1. Tipo de Vivienda
I01_IDEM_ESTRUC	E1. Tipo de Estructura
V01_VIV	V1. Tipo de Vivienda
V01_1_VIV_PARTICULAR	V1.1 Vivienda particular
V01_2_VIV_COLECTIVA	V1.2 Vivienda colectiva
V03_VIV_PARED	V3. Material predominante de pared
V04_VIV_Techo	V4. Material predominante de techo

V05_VIV_PISO	V5. Material predominante de piso
V06_VIV_CUARTOS	V6. Número de cuartos
V17_VIV_NUM_HOGARES	V17. Número de hogares
V18_VIV_NUM_PERSONAS	V18. Número de personas
V07_VIV_TENENCIA	V7. Tenencia de la vivienda
V08_VIV_TIPO_SANIT	V8. Tipo de servicio sanitario
V09_VIV_USO_SANIT	V9. Uso del servicio sanitario
V11_VIV_AGUA	V11. Disponibilidad de agua
V12_VIV_PROVIENE_AGUA	V12. Procedencia del agua
V12_1_VIV_ABASTO_AGUA	V12.1 Forma de abastecimiento
V10_VIV_AGUAS_GRISES	V10. Manejo de aguas grises
V13_VIV_FUENTE_ENERGIA	V13. Fuente principal de energía
V14_VIV_COMBUSTIBLE_COCINA	V14. Combustible para cocinar
V15_VIV_ELIM_BASURA	V15. Método de eliminación de basura
V16_VIV_OLLA_COMUN	V16. Participación en olla común

Conclusiones del Preprocesamiento y Exploración Inicial

Este primer notebook ha establecido una base sólida para el análisis multivariado de los datos censales de vivienda. La limpieza, codificación y selección de variables se han realizado de manera rigurosa para garantizar la calidad y la reproducibilidad del análisis.

Registros Procesados


El dataset inicial contenía más de 2.2 millones de registros, lo que subraya la necesidad de técnicas de reducción de dimensionalidad.

Columnas Iniciales

La preparación de los datos es un paso crítico que impacta directamente en la calidad de los resultados de la reducción de dimensionalidad y el clustering. La identificación y el tratamiento de valores faltantes, el renombrado de columnas y la conversión de tipos de datos son esenciales para un análisis preciso y significativo.

Reducción de Dimensionalidad

- El notebook 2 tiene un enfoque interpretativo más claro: visualizaremos cómo cambian los patrones de las viviendas según su grado de urbanización (GHS_L1) y su relación con:
- Tipo de vivienda
- Materiales (pared, techo, piso)
- Servicios (agua, saneamiento, energía)
- Presión ocupacional (cuartos, hogares, personas)
- Para lograrlo:
- Limpiamos solo las variables necesarias
- Imputamos según el tipo
- Escalamos donde corresponde
- Reducimos dimensionalidad con PCA y UMAP
- Graficamos manteniendo el eje de análisis: urbanización




Los Valores Ideales para el 80 % de la varianza Acumulada



Descripción de dataset

```
# Cargar dataset ya renombrado desde Notebook 01
df = pd.read_csv("dataset_limpio.csv")
print(df.shape)
df.head()
(2270026, 35)
```

Varianza Acumulada



Muestreo ponderado

Descripción: Se selecciona la librería pandas.DataFrame.sample de 50,000 registros

Y se procede a hacer una comparación de los tres modelos Coloreando por Urbanización

```
color_var = "ghs_l1" # la variable para colorear

X_sample_enc = X_enc.copy()
y_color = X_imp[color_var].reset_index(drop=True)

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_sample_enc)

# PCA
pca = PCA(n_components=2, random_state=42)
pca_res = pca.fit_transform(X_scaled)

# t-SNE
tsne = TSNE(
    n_components=2,
    perplexity=30,
    learning_rate='auto',
    init='pca',
    random_state=42
)
tsne_res = tsne.fit_transform(X_scaled)

# UMAP
umap_model = umap.UMAP(
    n_neighbors=30,
    min_dist=0.1,
    n_components=2,
    random_state=42
)
umap_res = umap_model.fit_transform(X_scaled)

# Unir resultados en un DataFrame para graficar
plot_df = pd.DataFrame({
    "pca_1": pca_res[:,0], "pca_2": pca_res[:,1],
    "tsne_1": tsne_res[:,0], "tsne_2": tsne_res[:,1],
    "umap_1": umap_res[:,0], "umap_2": umap_res[:,1],
    color_var: y_color.values
})
```

```

}))

# Graficar
plt.figure(figsize=(18,5))

plt.subplot(1,3,1)
sns.scatterplot(data=plot_df, x="pca_1", y="pca_2", hue=color_var, s=8,
palette="tab10")
plt.title("PCA")


plt.subplot(1,3,2)
sns.scatterplot(data=plot_df, x="tsne_1", y="tsne_2", hue=color_var, s=8,
palette="tab10")
plt.title("t-SNE")

plt.subplot(1,3,3)
sns.scatterplot(data=plot_df, x="umap_1", y="umap_2", hue=color_var, s=8,
palette="tab10")
plt.title("UMAP")


plt.tight_layout()
plt.show()

```

La comparación revela cómo cada técnica captura patrones de urbanización y estructura de viviendas bajo distintos supuestos (lineales vs no lineales). Te lo explico a fondo y te dejo recomendaciones prácticas para clustering y reporte institucional.



PCA



Naturaleza: Proyección lineal que maximiza varianza global en ejes ortogonales.

Separación observada:

PC1/PC2 muestran una separación moderada: los grupos 1, 2 y 3 se solapan, pero suelen distribuirse en gradientes —uno de los ejes captura componentes “macro” (materiales/servicios), el otro “presión ocupacional/tenencia” u otro bloque conceptual.

Patrones globales: diferenciales amplios de condiciones (calidad de materiales, acceso a agua/energía, saneamiento).


Limitación: no modela relaciones no lineales; si la urbanización se asocia con combinaciones complejas de categorías (one-hot) y conteos, parte de la estructura queda “aplanada”.

Cuándo usarlo:

Exploración inicial y reporte: aporta componentes interpretables vía cargas (eigenvectors).

Features para clustering: si quieres k-means/DBSCAN sobre proyección, retén $\geq 80\%$ de varianza con más de 2 PCs (tu análisis sugiere que 10 PCs acumulan $\sim 67.5\%$; probablemente necesites 13–15 PCs para $\geq 80\%$).

t-SNE



Naturaleza: Embedding no lineal que preserva vecindades locales; genera “islas” de puntos similares.

Separación observada:

Clústeres densos locales: las tres clases se ven más definidas por pequeños conglomerados, aunque la geometría global (distancias entre grupos) puede ser engañosa.

Micro-vecindades: viviendas con combinaciones de materiales/servicios muy parecidas colapsan en núcleos compactos.


Limitación: parámetros (perplexity, learning_rate, init) cambian la forma; las distancias entre clústeres NO son comparables a escala global. Reproducibilidad sensible.

Cuándo usarlo:

Visualización de subgrupos finos: excelente para resaltar patrones locales, detectar subtipologías (p. ej., “urbanización 2 con techo X y sanitario Y”).

No recomendado como base directa de clustering por su inestabilidad global; mejor usarlo como apoyo visual.

UMAP



Naturaleza: Embedding no lineal que equilibra estructura local y global utilizando teoría de variedades.

Separación observada:

Clústeres más coherentes y separaciones más claras que PCA, con mejor disposición espacial que t-SNE (relaciones entre grupos son más interpretables).

Relaciones de vecindad y continuidad: refleja transiciones entre niveles de urbanización donde materiales/servicios cambian gradualmente.

Ventajas: estable con semilla fijada, parametrizable (`n_neighbors`, `min_dist`) para controlar densidad y continuidad.


Cuándo usarlo:

Visualización para narrativa institucional: más clara para audiencias no técnicas.

Pre-embedding para clustering (HDBSCAN/DBSCAN): útil si quieres descubrir subtipologías con robustez.

Segundo Análisis utilizando todo el Set de Datos Reducción de Dimensionalidad

Descripción para Obtener comparación y el proceso de mejorar nuestro Modelo decidimos Integrar el Análisis de la Herramienta ArcGIS que permite aplicar Reduccion de Dimensionalidad y contine el lenguaje Python y Notebook como formas de trabajo .




Seleccionamos los 6 millones de Registros y solo nos enfocamos Igual en Urbanización

HOGAR_TIPO – Tipo de hogar (categórica)

INFO_TOTAL – Información total del hogar (numérica)

GHS_DUG_L1, GHS_DUG_L2 – Clasificación geoespacial (categóricas)

Geográficas complementarias: DEPTO, DEPTODESC, MUNIC, MUNICDESC, DISTO, DISTODESC, COD_PROP, COD_VIV



PCA SEGUNDO ANALISIS

Este gráfico revela una estructura latente lineal en tu dataset.


PC1 representa una combinación de variables geográficas (DEPTODESC, MUNICDESC, DISTODESC) y urbanización (GHS_DUG_L1/L2), lo que sugiere que este eje captura la estructura territorial y el grado de urbanización.

PC3 muestra contrastes entre regiones (DEPTO, DISTO positivo vs MUNIC negativo), lo que indica una polarización territorial: algunas zonas tienen condiciones muy distintas en términos de densidad o infraestructura.


Distribución por GHS_DUG_L1:

Los grupos 1, 2 y 3 se distribuyen en gradientes, pero con solapamientos. Esto es típico en PCA, donde la separación depende de la varianza explicada.

El grupo 3 (más urbano) tiende a concentrarse en una zona del plano, mientras que el grupo 1 (más rural) se dispersa más.



T-SNE



Agrupamiento por clasificación geoespacial


Este gráfico muestra una proyección no lineal que preserva vecindades locales. Aquí lo que se observa:

- **Clústeres densos y bien definidos:** cada nivel de GHS_DUG_L1 forma “islas” compactas, lo que indica que las viviendas con condiciones similares se agrupan fuertemente.
- **Separación más clara entre niveles:** los grupos 1, 2 y 3 están bien diferenciados, aunque las distancias entre ellos no son interpretables globalmente.
- **Color bar continua (1.5 a 3.75):** sugiere que GHS_DUG_L1 fue tratado como variable continua, lo cual puede ayudar a visualizar transiciones suaves entre niveles.

UMAP

Este gráfico muestra una proyección no lineal que equilibra estructura local y global:

- Separación clara entre niveles de urbanización, con transiciones suaves.
- Color bar continua (1.0 a 3.75): permite visualizar cómo las viviendas se distribuyen a lo largo de un gradiente urbano-rural.
- Distribución espacial coherente: los grupos no solo están separados, sino que sus posiciones reflejan relaciones reales entre condiciones materiales y servicios



Conceptos y Técnicas de Clustering

En el análisis de datos, el clustering es una técnica fundamental para descubrir patrones ocultos. Nos permite agrupar datos similares sin conocimiento previo de sus categorías, revelando estructuras naturales. Exploraremos cómo evaluar la calidad de estos agrupamientos y las herramientas clave para su implementación.

El modelo tiene un número de clústeres que refleja la estructura real de los datos. Para lograrlo, utilizamos métricas como la inercia y el coeficiente de silueta, que sirven como guías estadísticas.

Objetivo Encontrar un número óptimo de clústeres que equilibre la simplicidad y la representatividad de los datos.

Métricas Clave Inercia y Coeficiente de Silueta son herramientas complementarias para orientar la elección de K.

Interpretación Estas métricas son guías, no decisiones absolutas, y deben interpretarse con el contexto del problema.

Nuestros parámetros para Evaluar un Clúster o hacer un "Buen Ajuste"

Inercia El método del codo busca el punto donde la curva de inercia se "aplana" significativamente, sugiriendo el K óptimo.

El coeficiente de silueta evalúa la calidad de la asignación de cada punto a su clúster, comparando su cohesión dentro del clúster y su separación de otros clústeres.

- **Rango:** Valores entre -1 y 1.
- **Cercano a 1:** Asignación perfecta, el punto está bien dentro de su clúster y lejos de otros.
- **Cercano a 0:** El punto está en la frontera entre clústeres.
- **Negativo:** El punto está mal asignado.

Construcción del Modelo

Basándonos en el análisis de inercia y coeficiente de silueta, procedemos a construir el modelo final de K-means con $K=3$. Este paso implica entrenar el modelo y obtener las etiquetas de clúster para cada punto de datos.

1	2	3
Inicialización Se crea un objeto <code>KMeans</code> con <code>n_clusters=3</code> y <code>random_state=42</code> para reproducibilidad.	Entrenamiento El método <code>km.fit_predict(X_scaled)</code> asigna cada punto a un clúster y ajusta los centroides.	Resultados Las etiquetas de clúster se almacenan en la variable <code>labels</code> , indicando la pertenencia de cada punto.

Notebook 03 Clustering_Final

03_clustering_final


Dataset reducido de 50,000 viviendas aplicando KMeans y Gaussian Mixture Models (GMM)— sobre una base de reducción de dimensionalidad (PCA + UMAP), y evaluado con tres métricas clave: Silhouette, Davies-Bouldin, y Calinski-Harabasz.

KMeans Mejor K encontrado: 7 (por Silhouette = 0.6343)

Silhouette mejora consistentemente de $k=3$ (0.53) a $k=10$ (0.73)

Davies-Bouldin disminuye (mejor) de 0.73 a 0.36


Calinski-Harabasz crece de 77,985 a 191,257



KMeans encuentra clústeres cada vez más definidos a medida que aumenta k. El salto en

Calinski-Harabasz entre $k=7$ y $k=10$ sugiere que los clústeres se vuelven más compactos y separados. Sin embargo, elegiste $k=7$ como punto de equilibrio entre interpretabilidad y calidad.


Comparación con urbanización (GHS_DUG_L1)



KMeans

- Todos los clústeres tienen una proporción dominante de urbanización nivel 3 ($\approx 44\text{--}47\%$)
- La distribución interna es estable: nivel 2 $\approx 33\%$, nivel 1 $\approx 21\text{--}22\%$
- No hay clústeres “especializados” por nivel urbano, pero sí gradientes internos

GMM



- Similar patrón: nivel 3 dominante en todos los clústeres ($\approx 44\text{--}48\%$)
- Clúster 7 destaca con 48.1% de nivel 3 $\rightarrow$ posible agrupamiento urbano denso
- Clúster 8 tiene mayor proporción de nivel 2 (34.6%) $\rightarrow$ posible perfil periurbano

Ambos modelos segmentan dentro de cada nivel urbano, no entre ellos. Esto sugiere que las variables latentes (materiales, servicios, presión ocupacional) generan subtipologías internas dentro de cada categoría de urbanización.

Modelo	Mejor K	Silhouette	Davies-Bouldin	Calinski-Harabasz	Segmentación
KMeans	7	0.6343	0.4864	85,369	Más compacta
GMM	10	0.7096	0.3861	113,481	Más flexible

- **KMeans:** útil para segmentación operativa, más interpretable.
- **GMM:** mejor ajuste a formas complejas, ideal para análisis fino.

Interpretación y Conclusiones del Análisis de Clusters Notebook 04

Este documento presenta la interpretación y las conclusiones derivadas del análisis de clusters realizado en el Notebook 03. El objetivo principal es comparar los resultados de diferentes algoritmos de clustering (KMeans, GMM, HDBSCAN, Agglomerative), perfilar los clusters en relación con la urbanización y los componentes reducidos (PCA/UMAP), y extraer insights accionables para la toma de decisiones.

Descripción de los Datos Utilizados

Para llevar a cabo el análisis de clusters, se empleó el archivo `df_50k_clusters.csv`. Este archivo contiene los datos procesados y seleccionados específicamente para este estudio. Se han incluido únicamente las columnas mínimas necesarias, lo que permite focalizar el análisis en las variables más relevantes.

Columnas Presentes en el Archivo

- `pca_1` y `pca_2`: Componentes principales obtenidos mediante Análisis de Componentes Principales (PCA), que resumen la información de las variables originales en dos dimensiones principales.
- `umap_1` y `umap_2`: Proyecciones de los datos utilizando el método UMAP, dirigido a reducir la dimensionalidad y preservar la estructura de los datos en un espacio de menor dimensión.
- `urbanizacion`: Variable que representa el grado o tipo de urbanización asociado a cada observación, fundamental para el perfilado de los clusters.
- `cluster_kmeans`: Etiqueta que indica el cluster asignado a cada observación mediante el algoritmo KMeans.
- `cluster_gmm`: Etiqueta correspondiente al cluster asignado por el algoritmo GMM (Gaussian Mixture Model).

La selección de estas columnas garantiza que el análisis posterior sea eficiente y centrado en los aspectos clave para el estudio de segmentación y perfilado urbano.

Estructura y Distribución de Clústeres Existentes


Se realizó un análisis de segmentación sobre el dataset reducido de 50,000 viviendas, utilizando técnicas de reducción de dimensionalidad (PCA y UMAP) como base para aplicar dos métodos de clustering: KMeans y Gaussian Mixture Models (GMM). El objetivo fue identificar agrupamientos latentes que reflejen patrones estructurales en las condiciones de vivienda y urbanización.

2. Clústeres detectados

Clúster KMeans

- Se identificaron **7 clústeres únicos**.
- Los clústeres más grandes fueron:
 - Clúster 4: 14,164 elementos
 - Clúster 2: 13,818 elementos
- La distribución por nivel de urbanización (GHS_DUG_L1) dentro de cada clúster fue relativamente estable:
 - Nivel 3 (urbano): ~45%
 - Nivel 2 (periurbano): ~33%
 - Nivel 1 (rural): ~22%


Interpretación: KMeans logró segmentar el espacio latente en agrupamientos compactos y balanceados, revelando subtipologías internas dentro de cada nivel urbano.



Clúster GMM

- Se identificaron **10 clústeres únicos**.
- Los clústeres más grandes fueron:
 - Clúster 5: 12,081 elementos
 - Clúster 3: 8,642 elementos
- La distribución por nivel de urbanización fue similar a KMeans, pero con mayor diferenciación en algunos clústeres:
 - Clúster 7: 48.1% urbano
 - Clúster 8: 34.6% periurbano

Interpretación: GMM permitió una segmentación más flexible, modelando la forma y dispersión de los clústeres con mayor precisión. Esto reveló agrupamientos con perfiles urbanos más definidos.



3. Evaluación técnica

Se utilizaron tres métricas para evaluar la calidad de los modelos:

Métrica	KMeans (k=7)	GMM (k=10)
Silhouette Score	0.6343	0.7096
Davies-Bouldin Index	0.4864	0.3861
Calinski-Harabasz	85,369	113,481

Conclusión técnica: Ambos modelos son válidos, pero GMM ofrece una segmentación más refinada y coherente, ideal para análisis detallado y generación de perfiles.

4. Exportación

El archivo final `df_50k_clusters.csv` contiene:

- Componentes PCA (`pca_1`, `pca_2`)
- Embedding UMAP (`umap_1`, `umap_2`)
- Nivel de urbanización (`urbanizacion`)
- Clúster asignado por KMeans (`cluster_kmeans`)
- Clúster asignado por GMM (`cluster_gmm`)

Este archivo está listo para ser utilizado en análisis posteriores, generación de reportes y visualización institucional.

Conclusiones y Próximos Pasos

El análisis de clustering ha proporcionado insights valiosos sobre la segmentación de viviendas. Se recomienda la implementación de KMeans (k=7) por su estabilidad y equilibrio.

Mejor Método KMeans (k=7) es el más equilibrado para la asignación de recursos.	Foco de Intervención Revisar los clusters minoritarios (1 y 6) para programas de mejora de vivienda.
Cruzar con Geografía Proyectar clusters en un mapa para identificar concentraciones espaciales.	Validación de Campo Verificar la correspondencia entre las etiquetas de cluster y la realidad observable.

Estos pasos asegurarán que los resultados del clustering se traduzcan en acciones concretas y efectivas.